

CHECKPOINT

02

**Prompt
Toolkit:
Engenharia
de Prompt
no E-
commerce**

**Davi
Monteiro
RM:
573290**

1. Visão Geral do Projeto

O presente projeto consiste no desenvolvimento de um **Toolkit Python** modular projetado para automatizar e otimizar a seleção de técnicas de engenharia de prompt em contextos corporativos. Através da integração com a API do **Ollama** e o uso do modelo **gpt-oss: 120b**, o sistema permite testar e validar múltiplas abordagens de interação com LLMs.

1.1 Domínio Escolhido: E-commerce & Customer Experience (CX)

O domínio de E-commerce foi selecionado devido à alta demanda por processamento de linguagem natural em escala. O toolkit foca em resolver três gargalos principais:

- **Triagem Automática:** Classificação rápida de sentimentos em reviews de produtos.
- **Extração de Entidades:** Identificação de números de pedido, produtos e defeitos em tickets de suporte.
- **Atendimento Customizado:** Geração de respostas baseadas em personas específicas.

"A automação da camada de triagem reduz o tempo de resposta inicial em até 70%, permitindo que analistas humanos foquem em casos de alta complexidade."

2. Definição de Tarefas

ID	Tarefa	Input Exemplo	Output Esperado
T1	Análise de Sentimento	"O produto chegou quebrado e o suporte não responde."	Negativo (Urgência: Alta)
T2	Extração de Dados	"Quero devolver meu Mouse Gamer (Pedido #4452)."	{ "prod": "Mouse", "id": 4452 }
T3	Geração de Resposta	Ticket de reclamação sobre atraso.	E-mail empático e profissional.

3. Arquitetura do Sistema

A aplicação foi construída sobre princípios de **Clean Code** e modularidade, garantindo a portabilidade e testabilidade do código.

3.1 Estrutura de Módulos

- **src/llm_client.py**: Gerencia a comunicação com o servidor Ollama local.
- **src/prompt_builder.py**: Implementa a lógica de construção da anatomia do prompt.
- **src/evaluator.py**: Calcula métricas de performance e densidade de tokens.

3.2 Fluxo de Dados

O fluxo inicia com o carregamento de `data/inputs.json`. O orquestrador submete cada entrada às técnicas de prompting e exporta os resultados para CSV e Gráficos.

4. Implementação das 4 Técnicas

As técnicas aplicadas seguem os fundamentos explorados nas Aulas 06 e 07 da FIAP:

4.1 Zero-Shot (ZS)

Baseline utilizando apenas a instrução direta. Eficaz para tarefas simples, mas limitado em extrações complexas.

4.2 Few-Shot (FS)

Inclusão de exemplos de "Pergunta/Resposta". Demonstrou ser a técnica mais robusta para garantir outputs estruturados.


4.3 Chain-of-Thought (CoT)

Instrução de raciocínio passo a passo. Fundamental para tarefas de extração lógica.

4.4 Role Prompting

Uso de personas detalhadas carregadas via JSON para garantir tom de voz e autoridade técnica.

5. Resultados e Comparativos



5.1 Análise de Custo (Tokens)

Técnica	Tokens Médios	Custo Relativo
Zero-Shot	45	Baixo
Few-Shot	280	Médio
Chain-of-Thought	110	Baixo-Médio
Role Prompting	150	Médio

6. Guia de Bolso: Recomendações

Objetivo	Técnica	Por que?
Formatação JSON	Few-Shot	Evita alucinações estruturais.
Empatia no Suporte	Role Prompting	Garante consistência no tom.

7. Reflexão Crítica

O projeto demonstrou que a engenharia de prompt sistemática reduz significativamente a necessidade de intervenção humana em processos de CX. O uso estratégico de Few-Shot compensa o custo extra de tokens ao eliminar erros estruturais.

Davi Monteiro - RM 573290
FIAP 2026